Zaawansowane Modele Liniowe

Regresja Poissona

Aleksandra Kozłowska

2026-04-01

Wprowadzenie

Omawiany zbiór danych z pliku "*sklep*" zawiera informacje o liczbie klientów przychodzących do pewnego sklepu w okresie około trzech miesięcy. W zbiorze znajdują się kolumny:

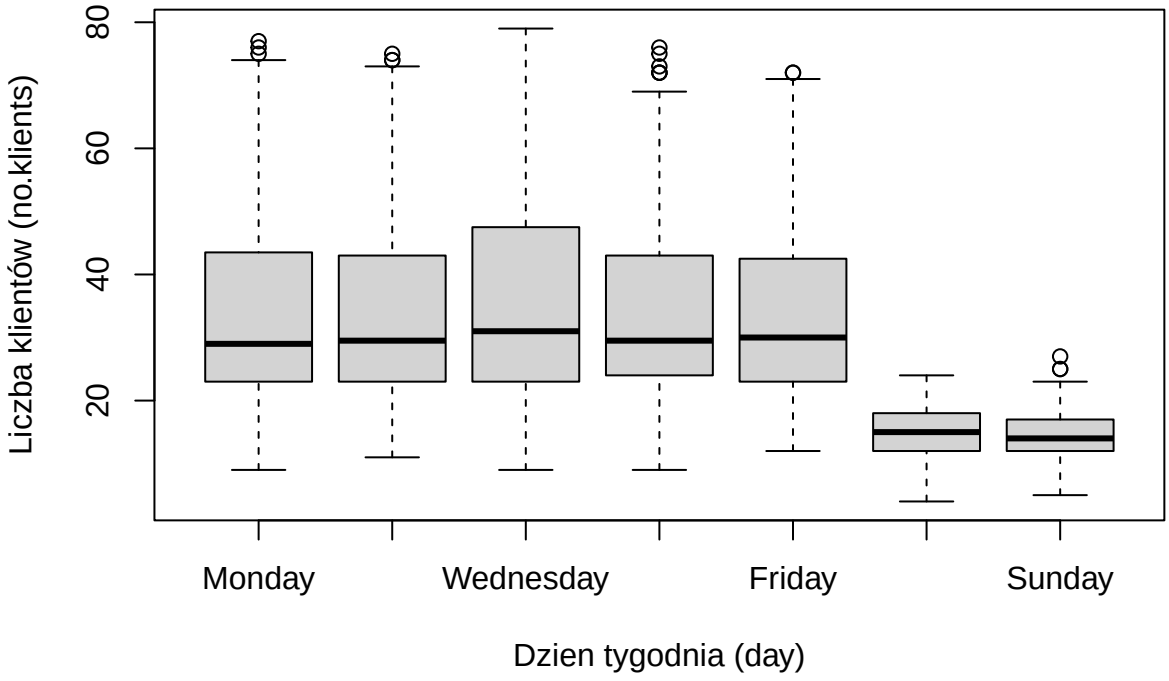
- *no.klients* - liczba klientów obsłużonych w danej godzinie (wartości: $0, 1, 2, ...$);
- *day* - dzień tygodnia (wartości: poniedziałek, wtorek, ..., niedziela);
- *hour* - godzina (wartości: $8, 9, \ldots, 23$);
- *events* - informacja o tym, czy w danym dniu miało miejsce jakieś wydarzenie sportowe (wartości: 0 - nie, 1 - tak).

Celem raportu jest przeanalizowanie danych za pomocą regresji Poissona, traktując liczbę obsłużonych klientów jako zmienną objaśnianą (y), a pozostałe zmienne jako potencjalne predyktory. Struktura danych wygląda następująco:

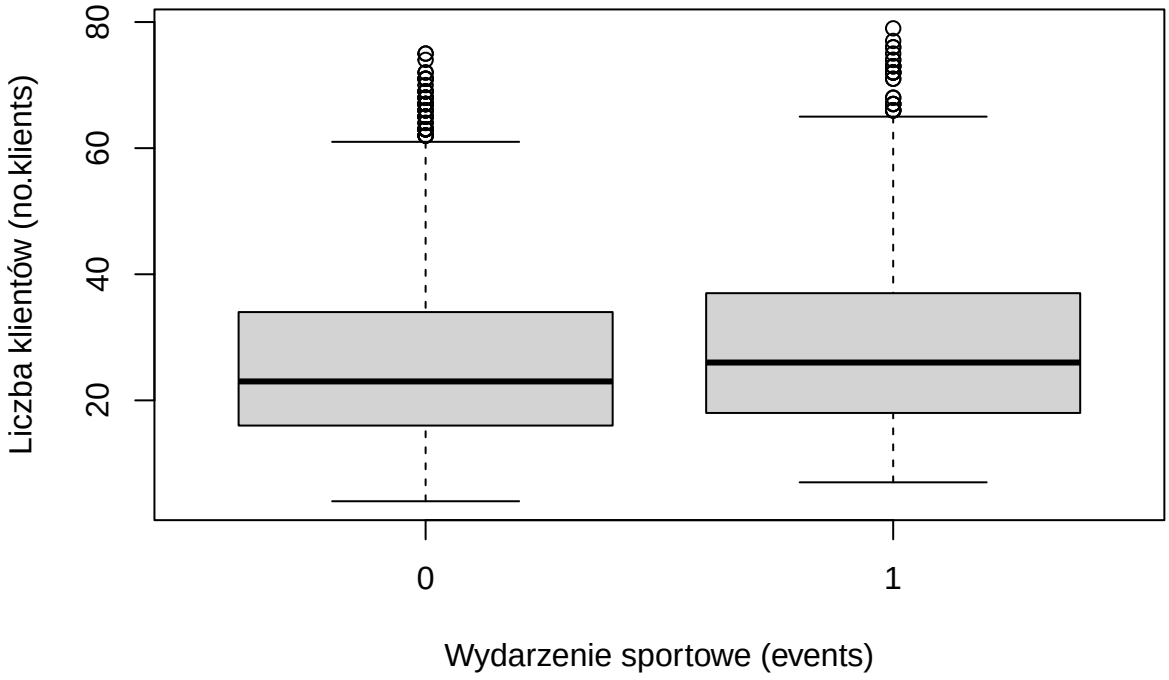
X	hour	day	events	no.klients
1	8	Monday	0	26
2	9	Monday	0	37
3	10	Monday	0	36
4	11	Monday	0	32
5	12	Monday	0	13
6	13	Monday	0	22
7	14	Monday	0	23
8	15	Monday	0	22
9	16	Monday	0	57
10	17	Monday	0	53

Wstępna analiza danych

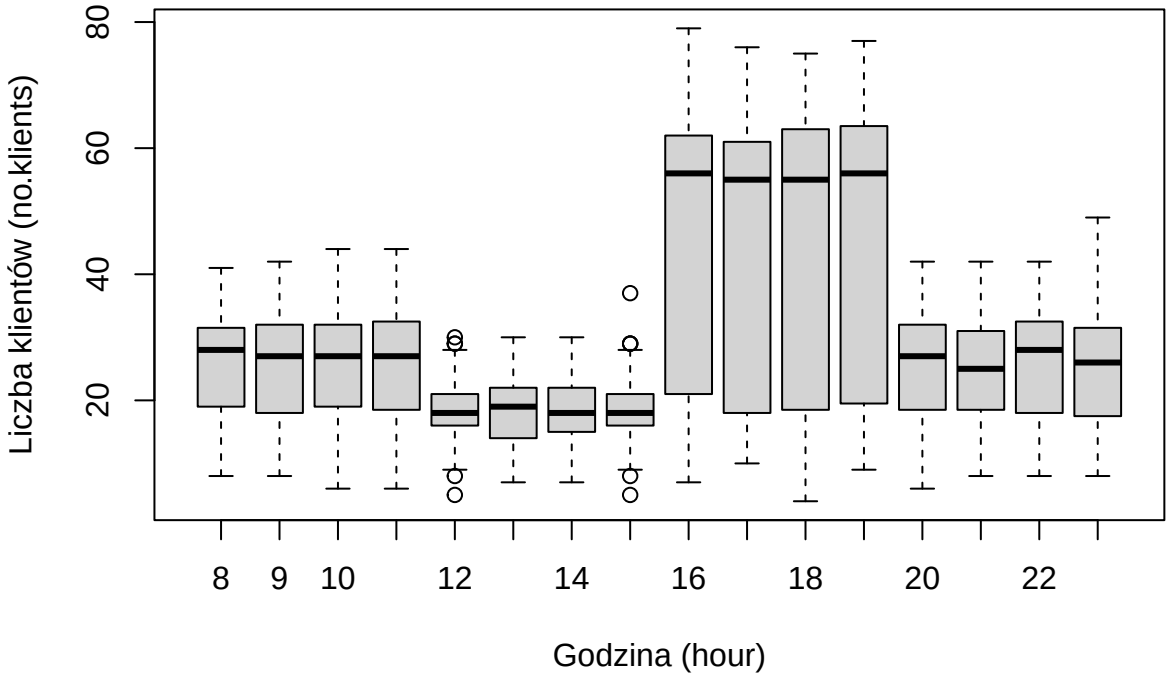
W ramach wstępnej analizy danych sporządzono boxploty zmiennej objaśnianej y w zależności od każdego predyktora.



Wykres pudełkowy liczby klientów w zależności od dnia tygodnia wskazuje na znaczącą różnice rozkładów zmiennej między dniami roboczymi i weekendowymi. Od poniedziałku do piątku mediana obsłużonych osób jest znacząco wyższa (ok. 30 klientów na godzinę) i towarzyszy jej duża zmienność danych oraz liczne wartości odstające sięgające 80 osób. Sugeruje to występowanie intensywnych godzin szczytu. Z kolei w soboty i niedziele ruch jest wyraźnie niższy (mediana ok. 15 klientów na godzinę) i charakteryzuje się znacznie mniejszą wariancją. Świadczy to o stabilniejszym i bardziej przewidywalnym napływie konsumentów. Jednocześnie w obu tych grupach różnice rozkładu między konkretnymi dniami wydają się dużo mniej znaczące.

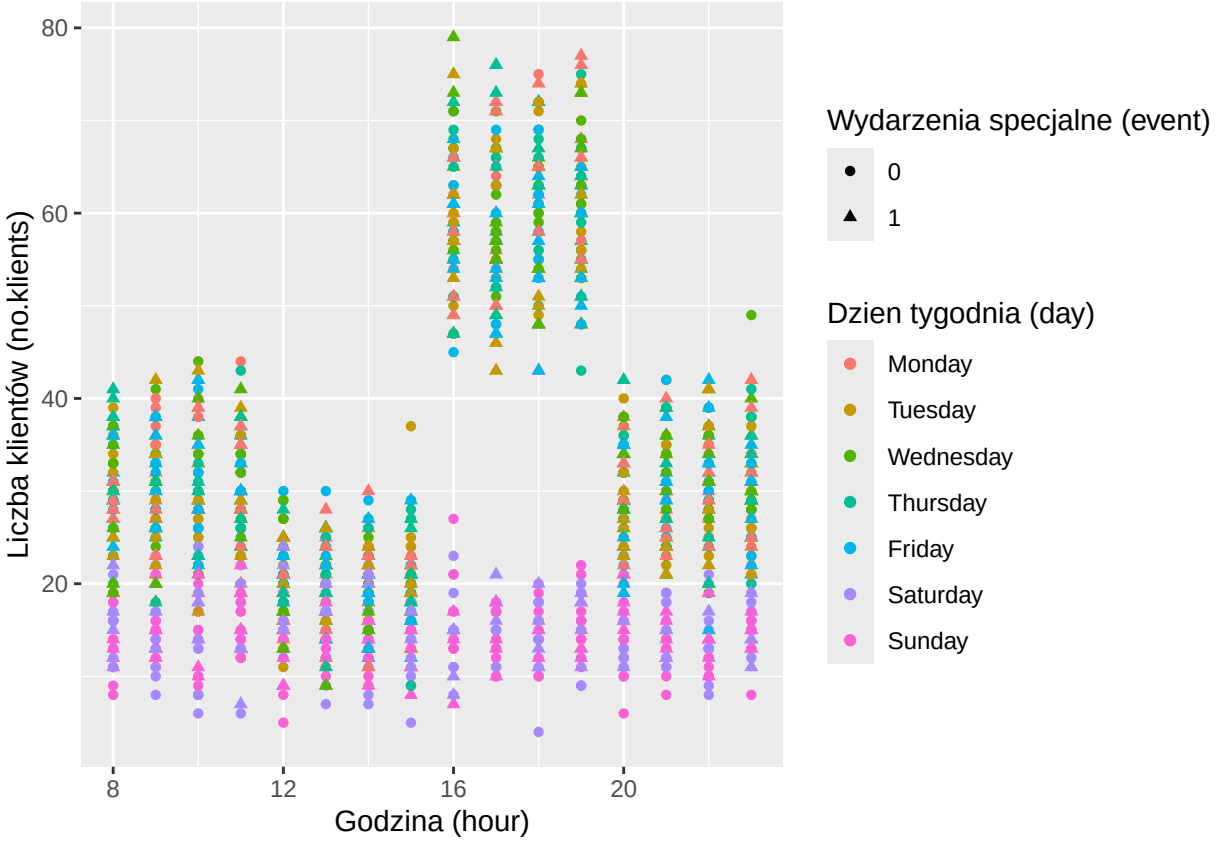


Wykres pudełkowy w podziale na występowanie wydarzeń sportowych (zmienna binarna *events*) wskazuje na nieznaczny wpływ tych zdarzeń na liczbę obsługiwanych klientów. W dniach, w których odbywały się wydarzenia sportowe, mediana liczby klientów jest wyższa o kilka jednostek w porównaniu do pozostałych dni. Można zaobserwować lekkie przesunięcie w górę całego rozkładu międzykwartylowego, co sugeruje niewielki wzrost zainteresowania zakupami powiązanych z tymi wydarzeniami. W obu grupach widoczna jest zbliżona, wysoka liczba wartości odstających, sięgających poziomu 80 klientów na godzinę. Zatem sama obecność wydarzeń sportowych nie jest czynnikiem generującym największe ekstrema, choć podnoszą one lekko bazowy poziom ruchu.



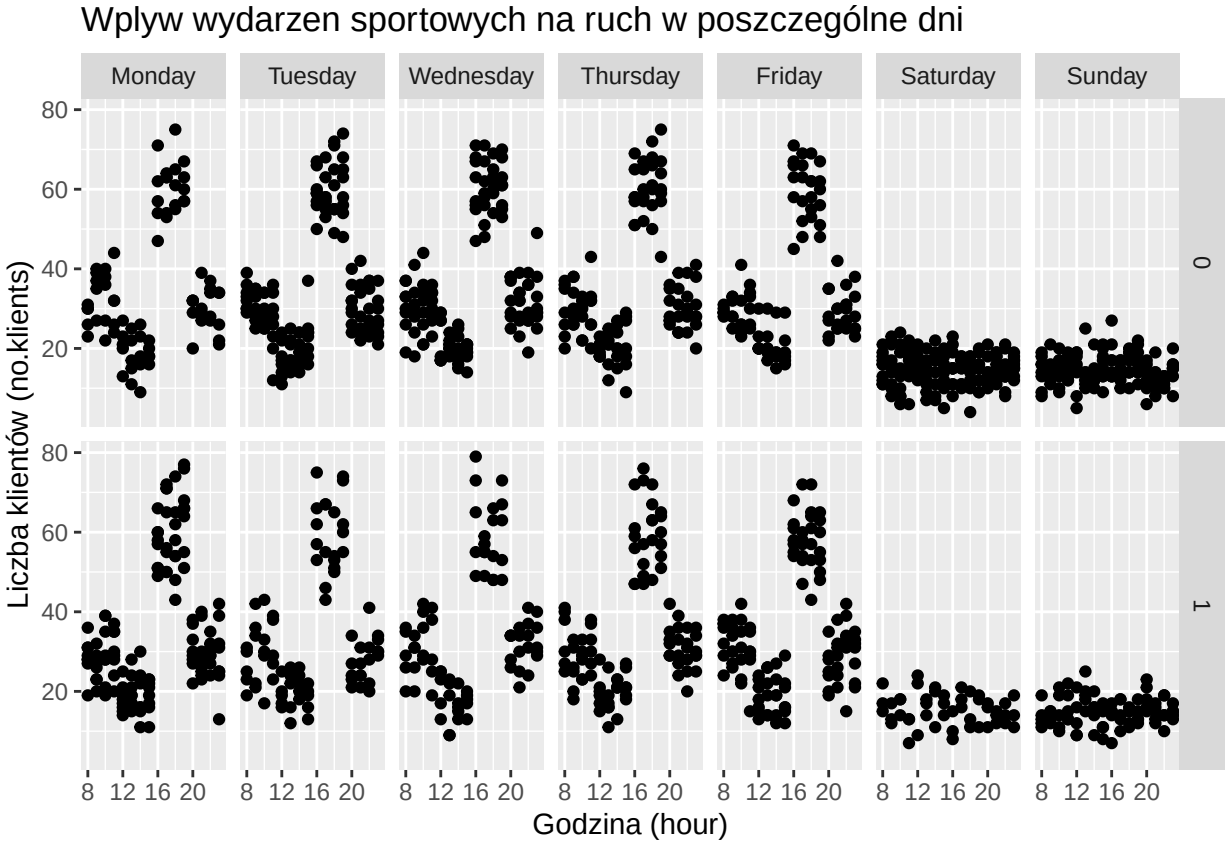
Wykres pudełkowy przedstawiający liczbę klientów w zależności od godziny (zmienna *hour*) ujawnia znaczne zmiany dynamiki natężenia ruchu w ciągu doby. Następuje istotny spadek liczby klientów w godzinach 12-15 oraz gwałtowny jej wzrost między godziną 16 a 19. W tym drugim przedziale czasowym mediana wzrasta blisko dwukrotnie względem godzin porannych i wieczornych, osiągając poziom ok. 55–60 klientów na godzinę. W godzinach wzmożonego ruchu odnotowuje się również największą dyspersję danych. Dolny kwartyl rozkładów zmiennej y w przedziale między godziną 16 a 19 osiąga podobne wartości, co w pozostałych porach dnia. Rozstęp międzykwartylowy zmiennej w godzinach porannych (8-11) i wieczornych (20-23) jest około trzykrotnie mniejszy niż w godzinach zwiększonego ruchu. Najmniejszą wariancją charakteryzują się jednak godziny południowe (12–15), kiedy to następuje przejściowy spadek frekwencji. Taka struktura zmienności pozwala na dokonanie podziału dnia na uśrednione pory, co 4 godziny.

Poniższy wykres punktowy stanowi zbiorcze zestawienie wpływu godziny, typu dnia oraz wydarzeń specjalnych na liczbę klientów. Pozwala on na jednoczesną obserwację korelacji między wszystkimi predyktorami modelu.



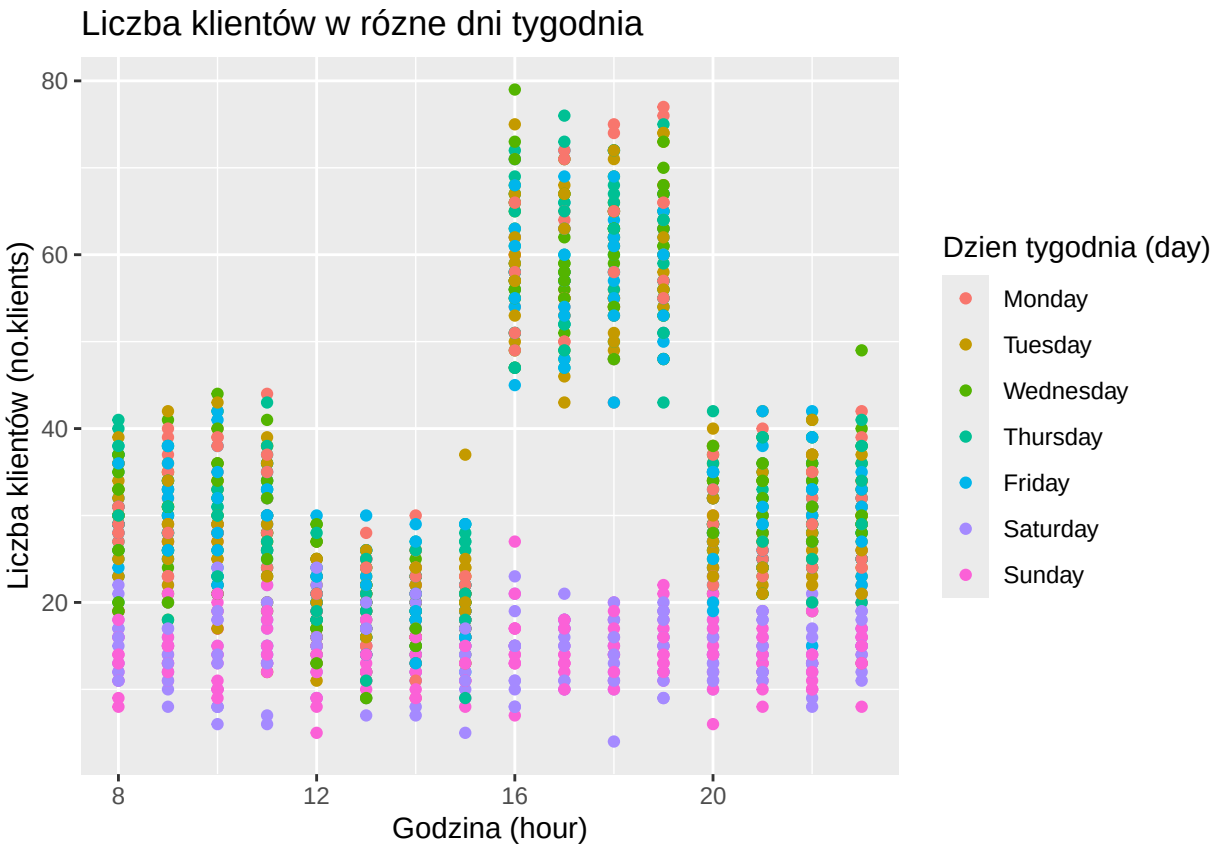
Wykres ten wskazuje na przyczynę zawyżonej wariancji rozkładu zmiennej y względem godziny w przedziale między 16 a 19. Występuje w nim widoczna separacja danych pochodzących z dni roboczych względem weekendów. W dni robocze liczba klientów obsługiwanych w ciągu godziny jest znacząco wyższa, podczas gdy w dni weekendowe rozkład utrzymuje się na podobnym poziomie, co w przypadku pozostałych pór dnia. Wskazuje to na występowanie istotnej interakcji między porą dnia a rodzajem dnia tygodnia. Na wykresie widać również inne omawiane wcześniej zależności tj. zmniejszoną liczbę klientów w soboty i niedziele (punkty w kolorach różowym i fioletowym), czy nieznacznie zwiększony ruch w dni z wydarzeniami sportowymi (punkty oznaczone trójkątami).

Porównano także dokładniej wpływ wydarzeń sportowych na liczbę klientów przy jednoczesnym uwzględnieniu pór dnia i godzin.



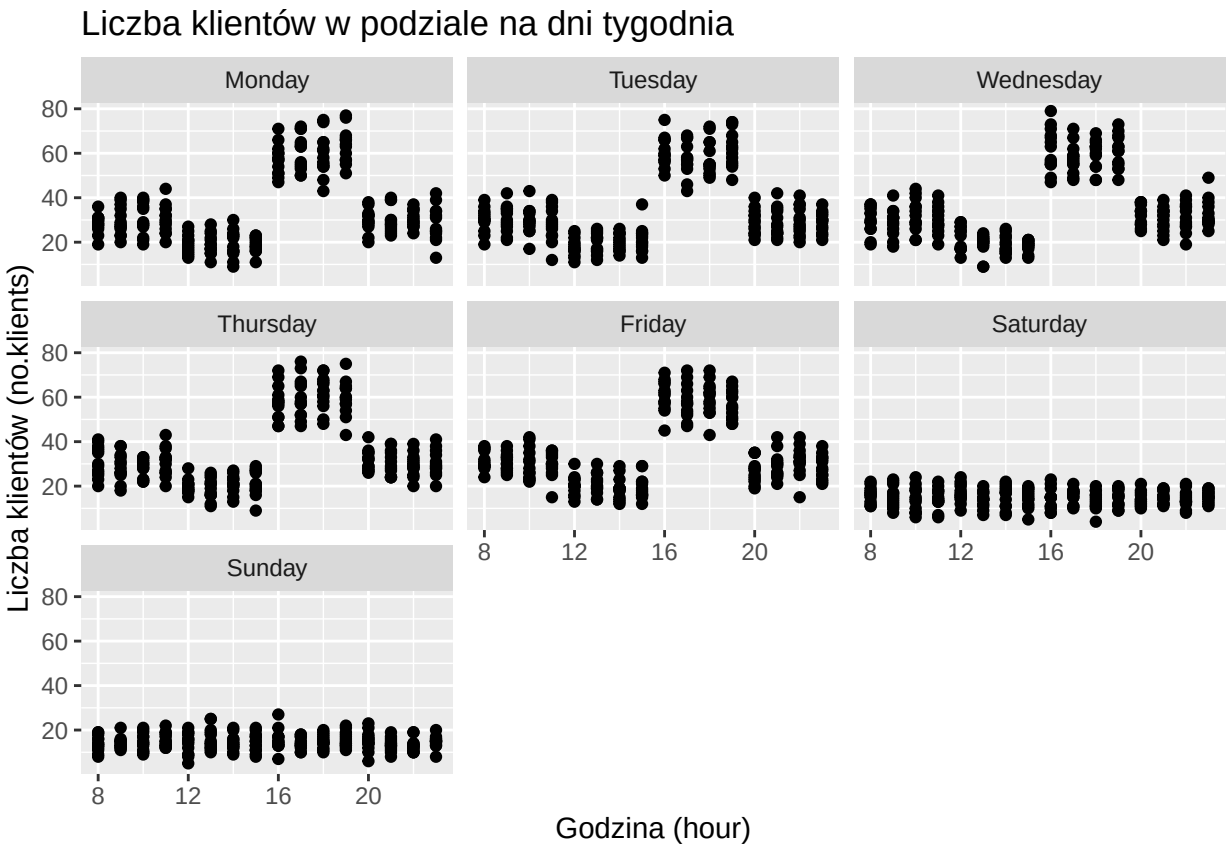
Powyższa wizualizacja potwierdza wcześniejsze przypuszczenia o dominującej roli podziału na dni robocze i weekendy, niezależnie od występowania wydarzeń sportowych. Porównując górny i dolny wiersz wykresów, można zauważyć, że obecność tych wydarzeń (wiersz dolny) nie zmienia zbytnio charakteru profilu godzinowego. Zachowane zostają zarówno popołudniowy wzmożony ruch w dni robocze, jak i stabilny poziom ruchu w weekendy.

Ponownie przeanalizowano interakcję między godziną a dniem tygodnia oraz ich wspólny wpływ na zmienną y, uproszczając wykres poprzez rezygnacje z dodatkowego oznaczania dni z wydarzeniem sportowym.



Uzyskany wykres w pełni potwierdza poprzednie obserwacje. Wyraźna, pionowa separacja chmury punktów w godzinach 16–19 uwidacznia różnicę między dniami roboczymi (klaster górny) a weekendami (klaster dolny), co wskazuje na interakcje obu zmiennych objaśniających. W dni weekendu rozkład zmiennej y jest stabilny na przestrzeni godzin. W dni robocze natomiast widoczne są zmiany w obrębie wspomnianego wcześniej podziału na 4-godzinne przedziały różnych pór dnia.

Ten sam podział rozkładu zmiennej y na pory dnia oraz dni tygodnia przedstawiono dokładniej na poniższym wykresie.



Wnioski z wykresu pozostają te same. Jednocześnie dużo wyraźniej można dostrzec skokową zmianę poziomu ruchu w dni robocze między przedziałami godzinowymi: 8-11, 12-15, 16-19 i 20-23.

Wybór optymalnego modelu

Po wstępnej analizie można postawić następujące hipotezy:

- zmienna *events* nie ma wpływu na y,
- istnieje możliwość pogrupowania dni oraz godzin tak, aby zredukować liczbę zmiennych,
- rozkład klientów w weekend jest jednostajny.

Skonstruowany model Poissona z interakcją pomiędzy wszystkimi regresorami, posiada aż 224 zmiennych. Model Poissona z pominięciem wpływu wydarzeń sportowych zmniejsza tę wartość o połowe. Zatem słusznym jest sprawdzenie, czy modele te są od siebie istotnie różne. Wykorzystano do tego test ilorazu wiarogodności (ANOVA z testem χ^2).

```
## Analysis of Deviance Table
##
## Model 1: no.klients ~ as.factor(hour) * day
## Model 2: no.klients ~ as.factor(hour) * day * as.factor(events)
##   Resid. Df Resid. Dev  Df Deviance Pr(>Chi)
## 1      1344     1475.7
## 2      1232     1359.6 112   116.13   0.3755
```

Porównanie obu modeli wykazało brak istotnych statystycznie różnic ($p = 0.3755 > 0.05$). Wynik ten pozwala na usunięcie aż 112 zbędnych parametrów, co stanowi znaczącą redukcję złożoności modelu bez utraty jego zdolności predykcyjnej.

Następnie zbadano zasadność utrzymania interakcji między godziną a dniem tygodnia poprzez analogiczny test (porównanie modelów z interakcją i bez interakcji).

```
## Analysis of Deviance Table
##
## Model 1: no.klients ~ as.factor(hour) + day
## Model 2: no.klients ~ as.factor(hour) * day
##   Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
## 1      1434     2412.5
## 2      1344     1475.7 90   936.79 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Wynik powyższego testu wskazuje, że różnica między modelami jest wysoce istotna statystycznie (p-wartość bliska zeru). Oznacza to, że wpływ godziny na liczbę klientów jest zależny także od dnia tygodnia. Jest to zgodne z intuicjami po wstępnej analizie danych - w dni robocze ruch w sklepie był uzależniony od godzin, podczas gdy w weekendy utrzymywał się na stabilnym poziomie.

W poprzedniej części raportu wskazywano na sensowność podziału dni na robocze i weekendowe oraz podzielenie godzin w ciągu dnia na 4-godzinne bloki. Obie te zmienne zaimplementowano i zbudowano kolejne modele Poissona, traktując nowe zmienne jako faktory. Model *m3* oparty na zmiennych *hour* i *rob* (dni robocze) ma 32 parametry, a model *m4* oparty na zmiennych *rob* i *pora* (pora dnia) ma ich już tylko 8. Następnie wykonano ponownie testy (ANOVA) porównujące: model *m3* do modelu z 112 zmiennymi oraz model *m3* z *m4*.

```
## Analysis of Deviance Table
##
## Model 1: no.klients ~ as.factor(hour) * rob
## Model 2: no.klients ~ as.factor(hour) * day
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1      1424     1545.0
## 2      1344     1475.7 80   69.218   0.7997
```

```
## Analysis of Deviance Table
##
## Model 1: no.klients ~ as.factor(pora) * rob
## Model 2: no.klients ~ as.factor(hour) * day
##   Resid. Df Resid. Dev  Df Deviance Pr(>Chi)
## 1      1448     1552.5
## 2      1344     1475.7 104   76.718   0.9794
```

Wyniki obu testów pozwalają na stwierdzenie, że modele te nie są istotnie różne. W przypadku porównania modelu z 112 zmiennymi z modelem *m3* p-wartość wyniosła 0.7997, a test dla modeli *m3* i *m4* była ona równa 0.9794. Obie wartości znacznie przewyższają poziom istotności $\alpha = 0.05$. Zatem zmniejszono potrzebną liczbę zmiennych o kolejne 104 zmienne (z 112 do 8). Choć wstępna analiza danych sugeruje, że interakcja między porami dnia a zmienną *rob* określającą typ dnia jest istotna, sprawdzono to dodatkowo porównując model *m4* z modelem bez interakcji *m5*.

```
## Analysis of Deviance Table
##
## Model 1: no.klients ~ as.factor(pora) * rob
## Model 2: no.klients ~ as.factor(pora) + rob
##   Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
## 1      1448     1552.5
## 2      1451     2419.8 -3   -867.3 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Wyniki testu ANOVA wskazują, że interakcja faktycznie jest istotna (p-wartość bliska zeru). Zatem model z interakcjami można uznać za optymalny. Ostatecznie liczba zmiennych w optymalnym modelu jest równa 8.

Porównanie dni roboczych i weekendowych

Bazując na wybranym optymalnym modelu m_4, wyznaczono teoretyczne wartości natężenia ruchu dla poszczególnych podgrup. W poniższych zestawieniach przedstawiono prognozowaną średnią liczbę klientów na godzinę ($\widehat{y}$), postać predyktora liniowego η oraz jego wartości punktowe. Tabele podzielono na dni robocze i weekendowe, aby zachować przejrzystość zestawienia i porównanać między sobą wyniki w obu podgrupach.

	Weekend 8-12	Weekend 12-16	Weekend 16-20	Weekend 20-23
Średnia liczba klientów na godzinę	14.79	14.95	14.87	14.37
Postać predyktora (η_i)	$\hat{\beta}_0$	$\hat{\beta}_0 + \hat{\beta}_1$	$\hat{\beta}_0 + \hat{\beta}_2$	$\hat{\beta}_0 + \hat{\beta}_3$
Wartość η_i	2.6938	2.7048	2.6990	2.6655

	Roboczy 8-12	Roboczy 12-16	Roboczy 16-20	Roboczy 20-23
Średnia liczba klientów na godzinę	30.01	19.71	59.64	29.98
Postać predyktora (η_i)	$\hat{\beta}_0 + \hat{\beta}_4$	$\hat{\beta}_0 + \hat{\beta}_1 + \hat{\beta}_4 + \hat{\beta}_5$	$\hat{\beta}_0 + \hat{\beta}_2 + \hat{\beta}_4 + \hat{\beta}_6$	$\hat{\beta}_0 + \hat{\beta}_3 + \hat{\beta}_4 + \hat{\beta}_7$
Wartość η_i	3.4015	2.9812	4.0884	3.4006

Analiza danych w tabelach jest spójna z wnioskami wyciągniętymi we wcześniejszej częsci raportu. Wyraźnie widać, że w weekendy ruch w sklepie jest bardzo przewidywalny i utrzymuje się na stałym, stosunkowo niskim poziomie około 15 klientów na godzinę. Sytuacja z dni roboczych jest zupełnie inna. Między godziną 16 a 20 następuje gwałtowny wzrost liczby osób – średnia skacze wtedy do poziomu ponad 55 klientów na godzinę. Tak duże różnice pokazują, dlaczego zastosowanie interakcji w modelu było niezbędne. Gdyby pominąć fakt, że wartości natężenia klientów w dni robocze są zupełnie inne niż w weekendy, model podawałby błędne, uśrednione wyniki. Dzięki wprowadzeniu parametrów interakcji ($\hat{\beta}_6$–$\hat{\beta}_8$), model m_4 uwzględnia skoki w natężeniu. Ostateczne wyniki są w pełni zgodne z danymi przedstawionymi na wykresach, co dowodzi, że model – mimo dużej redukcji zmiennych – bardzo dobrze opisuje rzeczywisty ruch w sklepie.

W celu potwierdzenia hipotezy o jednostajnym rozkładzie ruchu w weekendy, przeprowadzono test istotności łącznej parametrów dotyczących pór dnia dla tej grupy (test Walda). Badano hipotezę zerową zakładającą, że współczynniki przy zmiennych pora2, pora3 oraz pora4 są równocześnie równe zero.

```
##
## Linear hypothesis test:
## as.factor(pora)2 = 0
## as.factor(pora)3 = 0
## as.factor(pora)4 = 0
##
## Model 1: restricted model
## Model 2: no.klients ~ as.factor(pora) * rob
##
##   Res.Df Df Chisq Pr(>Chisq)
## 1   1451
## 2   1448  3 1.383     0.7095
```

Wynik testu ($p = 0.7095 > 0.05$) wskazuje na brak podstaw do odrzucenia hipotezy zerowej. Oznacza to, że w dni weekendowe zmiany pory dnia nie wpływają w sposób istotny statystycznie na liczbę obsługiwanych klientów. Wynik ten potwierdza, że dla soboty i niedzieli model można uprościć do samej wartości średniej (wyrazu wolnego), co jest zgodne z wcześniejszymi obserwacjami.

Dobór odpowiedniego grafiku pracy

Uzyskany model pozwala na sformułowanie praktycznych dotyczące zarządzania personelem. Poniżej zaproponowano optymalną liczbę pracowników na konkretne godziny (planowy grafik pracy). Przyjęto założenie, zgodnie z którym jeden pracownik jest w stanie obsłużyć do 20 klientów w ciągu godziny. Na podstawie wartości oczekiwanych $\hat{y}$ wyznaczono niezbędną obsadę (zastosowano zaokrąglenie w górę). Zestawienie zalecanej liczby pracowników przedstawiono w poniższej tabeli:

Table 2: Zalecana obsada personelu

Dzień i Pora	Przewidywani klienci/h	Liczba pracowników
Weekend 8-12	14.79	1
Weekend 12-16	14.95	1
Weekend 16-20	14.87	1
Weekend 20-23	14.37	1
Roboczy 8-12	30.01	2
Roboczy 12-16	19.71	1
Roboczy 16-20	59.64	3
Roboczy 20-23	29.98	2